



人工智能+数学物理 I

授课人：康奇宇




- 1 偏微分方程传统数值方法**
- 2 神经网络求解偏微分方程
- 3 神经网络求解应用实例

无处不在的偏微分方程：




热传导方程

$$\frac{\partial u}{\partial t} = \kappa \Delta u$$




波动方程

$$\frac{\partial^2 u}{\partial t^2} = c^2 \Delta u$$



纳维-斯托克斯方程





$$\begin{cases} \frac{\partial \rho}{\partial t} + \nabla \cdot (\rho \mathbf{u}) = 0 \\ \rho \left(\frac{\partial \mathbf{u}}{\partial t} + (\mathbf{u} \cdot \nabla) \mathbf{u} \right) = \\ -\nabla p + \mu \Delta \mathbf{u} + (\lambda + \mu) \nabla (\nabla \cdot \mathbf{u}) + \rho \mathbf{f}. \end{cases}$$



薛定谔方程

$$i\hbar \frac{\partial \psi}{\partial t} = -\frac{\hbar^2}{2m} \Delta \psi + V\psi$$

偏微分方程应用




偏微分方程连续本质

- 什么是 PDE?

偏微分方程描述的是**连续函数**所满足的方程。在物理模型中，我们通常假设物理量（如温度、流速、压力）在空间中是连续分布的。

- 无限维特性


由于连续区域包含无穷多个点，未知量本质上具有**无穷多个自由度**。这意味着在每一个坐标点上，函数都有一个独立的值。



为何计算机无法直接求解



连续区域点的数量



存储与计算的鸿沟

- 计算机内存是有限的，无法存储无穷维度的信息。
- 连续函数在每一个点上的值无法逐一计算。
- 必须寻求一种将 " 无限 " 映射到 " 有限 " 的方法。


简单案例

二维 Poisson 方程标准形式:

$$\nabla^2 u(x, y) = \frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} = f(x, y)$$

其中:

- $u(x, y)$ 是待求的未知函数 (例如电势)。
- $f(x, y)$ 是已知源项 (例如电荷分布)。
- ∇^2 是拉普拉斯算子。



数值解到底在做什么

连续问题：未知量是整个函数


$$-\Delta u(x, y) = f(x, y), \quad (x, y) \in \Omega$$

$u: \Omega \rightarrow \mathbb{R}$ 区域含无穷多个点 $\Rightarrow$ 无穷多个自由度，计算机无法直接存储和求解


离散化：用有限维向量近似

$$\mathbf{u} = [u_1, \dots, u_n]^\top \in \mathbb{R}^n$$

u_i 的可能含义：网格点函数值、基函数展开系数、控制体平均值



↓ 离散化



$$u: \Omega \rightarrow \mathbb{R} \Rightarrow u \in \mathbb{R}^n$$

离散化把 PDE 变成四种代数对象

静态线性问题

$$\mathbf{A}\mathbf{x} = \mathbf{b}$$

时间相关问题

$$\mathbf{M}\dot{\mathbf{u}} + \mathbf{K}\mathbf{u} = \mathbf{b}(t)$$

非线性问题

$$\mathbf{F}(\mathbf{u}) = 0$$

特征值问题

$$\mathbf{K}\mathbf{v} = \lambda\mathbf{M}\mathbf{v}$$

不同离散化方法，本质上是对三个问题给出不同回答

- 1 如何表达 $\mathbf{u}$? 网格点值 / 分片多项式系数 / 全局基展开系数 / 控制体平均值
- 2 如何近似微分算子? 差商 / 积分（散度定理） / 基函数求导
- 3 如何要求方程“成立”? 逐点成立 / 积分意义下成立 / 投影（Galerkin）意义下成立


入门模型：Poisson 方程

变系数 Poisson ($a \equiv 1$ 时退化为 $-\Delta u = f$)

$$-\nabla \cdot (a(\mathbf{r}) \nabla u) = f, \quad u|_{\partial\Omega} = g$$

椭圆型 PDE 的典型代表，出现在：

- 静电场： u 是电势， f 是电荷密度
- 稳态热传导： u 是温度， a 是热导率
- 不可压流的压力 Poisson 方程
- 弹性力学的简化模型



随机系数场 $a(r)$ (Gaussian Random Field)

变系数 $a(r)$ 反映非均匀介质（渗流、非均匀热导率）——也是神经算子数据生成中随机化的对象

空间离散方法

有限差分 FDM · 有限元 FEM · 有限体积 FVM · 谱方法

有限差分法 FDM: 用差商代替导数

思想最直接的方法: 逐点要求方程成立

Taylor 展开

$$u(x_i \pm h) = u(x_i) \pm h u'(x_i) + \frac{h^2}{2} u''(x_i) \pm \frac{h^3}{6} u'''(x_i) + O(h^4)$$

前差 · $O(h)$

$$\frac{u_{i+1} - u_i}{h}$$

后差 · $O(h)$

$$\frac{u_i - u_{i-1}}{h}$$

中心差分 · $O(h^2)$

$$\frac{u_{i+1} - u_{i-1}}{2h}$$

二阶导数: 中心差分, 误差 $O(h^2)$

$$u''(x_i) \approx \frac{u_{i+1} - 2u_i + u_{i-1}}{h^2}$$

逐点列方程:

每个网格点对应一条代数方程

一维 Poisson: 从差分格式到三对角矩阵

$-u'' = f, u(0) = u(1) = 0$, 均匀网格 $x_i = ih$

$$-\frac{u_{i+1} - 2u_i + u_{i-1}}{h^2} = f(x_i), \quad i = 1, \dots, N-1$$

- 对每个内点 $i = 1, \dots, N-1$ 写一条方程
- 整理成线性系统 $Au = b$
- A 是三对角、对称正定矩阵

$$Au = b$$


2	-1					
-1	2	-1				
	-1	2	-1			
		-1	2	-1		
			-1	2	-1	
				-1	2	-1
					-1	2

$$A = (1/h^2) \cdot \text{tridiag}(-1, 2, -1)$$

二维 Poisson: 五点格式


两个方向都做中心差分 ($\Delta x = \Delta y = h$)

$$\frac{4u_{i,j} - u_{i+1,j} - u_{i-1,j} - u_{i,j+1} - u_{i,j-1}}{h^2} = f_{i,j}$$



“自己 + 上下左右”

- 内点未知数按行优先排成向量
- 每行最多 5 个非零元
- 得到大型稀疏线性系统 $A u = b$



矩阵稀疏结构 (12×12 网格)

边界条件“并入”矩阵

以左边界 $x = 0$ 附近的第一个内点 $(1, j)$ 为例

Dirichlet: 给定函数值 $u_{0j} = g_j$

边界值已知，不是未知量，直接移到右端：

$$\frac{4u_{1,j} - u_{2,j} - u_{1,j-1} - u_{1,j+1}}{h^2} = f_{1,j} + \frac{g_j}{h^2}$$

⇒ 表现为对右端项 b 的修正

Neumann: 给定导数 $\partial u / \partial x|_0 = 0$

用差分近似导数，得到边界值与内点的关系：

$$\frac{u_{1,j} - u_{0,j}}{h} = 0 \Rightarrow u_{0,j} = u_{1,j}$$

代回五点格式：系数 4 变成 3

⇒ 改变矩阵对应行的系数

另一种写法：ghost point (虚拟节点)

$$\left. \frac{\partial u}{\partial x} \right|_{x=0} \approx \frac{u_{1,j} - u_{-1,j}}{2h}$$

引入虚拟节点 u_{-1j} ，保持中心差分结构与 $O(h^2)$ 精度

有限元法 FEM：从强形式到弱形式

先把 PDE 转写成弱形式，再在**分片多项式空间**里寻找解

$-\nabla \cdot (a \nabla u) = f$, 两边乘一个测试函数 v (满足 $v|_{\partial\Omega} = 0$)


$-\int_{\Omega} \nabla \cdot (a \nabla u) v \, d\mathbf{r} = \int_{\Omega} f v \, d\mathbf{r}$ 利用格林公式分部积分得到:

弱形式

$$\int_{\Omega} a \nabla u \cdot \nabla v \, d\mathbf{r} = \int_{\Omega} f v \, d\mathbf{r}, \quad \forall v$$

为什么要弱形式?

二阶导数 $\rightarrow$ 一阶导数, 解的光滑性要求降低; 可以用只 C^0 连续的分片多项式近似 u —— 这正是 FEM 处理复杂几何的关键。



三角剖分网格 (mesh)

Galerkin 离散：刚度矩阵

分片线性近似：节点值 $\times$ 形函数 (hat function)


$$u_h(\mathbf{r}) = \sum_{j=1}^n u_j \phi_j(\mathbf{r})$$

代入弱形式，取 $v = \phi_i$

$$K_{ij} = \int_{\Omega} a \nabla \phi_j \cdot \nabla \phi_i \, d\mathbf{r}, \quad b_i = \int_{\Omega} f \phi_i \, d\mathbf{r}$$

$$\mathbf{K} \mathbf{u} = \mathbf{b}$$

$\mathbf{K}$ 是刚度矩阵，仍然稀疏：仅当节点 i, j 共享某个单元时 $K_{ij} \neq 0$



形函数 ϕ_j ：节点 j 上取 1，其余节点取 0

$\mathbf{u}$ 由节点取值唯一决定，几何复杂也照样剖分

质量矩阵与广义特征值问题

热方程 $u_t - \nabla \cdot (a \nabla u) = f \rightarrow$ 半离散系统

$$\mathbf{M}\dot{\mathbf{u}}(t) + \mathbf{K}\mathbf{u}(t) = \mathbf{b}(t)$$

$$M_{ij} = \int_{\Omega} \phi_j \phi_i \, d\mathbf{r}$$

特征值问题 $-\Delta u = \lambda u$ (求基本模态)

$$\mathbf{K}\mathbf{v} = \lambda \mathbf{M}\mathbf{v}$$

FEM $\Rightarrow$ 广义特征值问题;

FDM 直接得到标准形式 $\mathbf{A}\mathbf{v} = \lambda \mathbf{v}$

有限体积法 FVM: 在控制体上离散积分守恒律

控制体内守恒量的变化 = 边界通量的净流入 $\Rightarrow$ 离散层面天然保持守恒

守恒形式 + 对控制体 C_i 积分 (散度定理)



$$\partial_t u + \nabla \cdot \mathbf{F}(u) = 0$$

$$\frac{d}{dt} \int_{C_i} u \, d\mathbf{r} + \int_{\partial C_i} \mathbf{F}(u) \cdot \mathbf{n} \, ds = 0$$

未知量: 控制体内的平均值

$$\bar{u}_i = \frac{1}{|C_i|} \int_{C_i} u \, d\mathbf{r}$$

不是某点的值,
而是小盒子的平均



$$C_i = [x_{i-1/2}, x_{i+1/2}]$$

相邻控制体通过界面通量耦合

最常用于: 流体力学、气体动力学、守恒律方程

FVM向量形式

把所有控制体平均值收集成一个向量

$$\mathbf{u}(t) = [\bar{u}_1(t), \bar{u}_2(t), \dots, \bar{u}_N(t)]^\top$$

对每个控制体写一条通量平衡方程 $\rightarrow$ 有限维动力系统

$$\mathbf{M}_{\text{cv}} \dot{\mathbf{u}}(t) = \mathbf{R}(\mathbf{u}(t)), \quad \mathbf{M}_{\text{cv}} = \text{diag}(|C_1|, \dots, |C_N|)$$

$\mathbf{R}(\mathbf{u})$: 边界通量的净流入

$$\mathbf{M}_{\text{cv}} \dot{\mathbf{u}}(t) + \mathbf{A}\mathbf{u}(t) = \mathbf{b}(t)$$

FVM 并不停留在积分形式: 数值通量把相邻控制体耦合起来, 最终同样得到 ODE 系统 / 稀疏矩阵方程, 矩阵项来自通量平衡

例: 一维迎风对流 (周期边界)

$$\dot{\mathbf{u}} = -\mathbf{A}\mathbf{u}$$

1					-1
-1	1				
	-1	1			
		-1	1		
			-1	1	
				-1	1

A 稀疏: 每行只耦合 C_i 与上游 C_{i-1}

谱方法：用全局基函数展开整个解

周期问题：Fourier 基 e^{ikx}

$$u_N(x) = \sum_{k=-K}^K \hat{u}_k e^{ikx}$$


微分 = 频域乘法

$$\frac{d}{dx} \iff ik, \quad \frac{d^2}{dx^2} \iff -k^2$$

周期 Poisson: $-u_{xx} = f$ 在频域逐模态解耦

$$k^2 \hat{u}_k = \hat{f}_k \Rightarrow \hat{u}_k = \hat{f}_k / k^2 \quad (k \neq 0)$$

$$f(x_j) \xrightarrow{\text{FFT}} \hat{f}_k \xrightarrow{\hat{u}_k = \hat{f}_k / k^2} \hat{u}_k \xrightarrow{\text{IFFT}} u(x_j)$$



不同频率的 Fourier 模态


借助 FFT: $O(N \log N)$

展开系数 vs 节点值

系数形式 (modal)

$$u_N(x) = \sum_{k=0}^N \hat{u}_k \phi_k(x)$$

未知量：系数 $\hat{u}_k$ ；算子是系数空间的矩阵（Fourier 下为对角）



$x_j = \cos(j\pi/N)$ ：端点附近更密集


Chebyshev-Gauss-Lobatto 节点：端点是网格点，Dirichlet 条件可直接替换矩阵首末行

节点形式 (collocation / 伪谱)

$$u_N(x) = \sum_{j=0}^N u_j \ell_j(x), \quad \ell_j(x_i) = \delta_{ij}$$

$$\mathbf{u}_x = \mathbf{D} \mathbf{u}, \quad D_{ij} = \ell'_j(x_i)$$

逐点操作直观（边界、非线性项），但谱微分矩阵 $\mathbf{D}$ 通常稠密



谱精度：

光滑解时误差近似指数下降

四种空间离散方法对比

	FDM 有限差分	FEM 有限元	FVM 有限体积	谱方法
未知量 u_i	网格点函数值	节点系数 (形函数)	控制体平均值	全局基系数 / 特殊节点值
微分近似	差商代替导数	弱形式 + 基函数求导	界面通量平衡	全局基函数精确求导
矩阵特点	稀疏 (带状)	稀疏 (单元邻接)	稀疏 (面邻接)	稠密, 规则区域可用 FFT
强项	简单易编程、规则网格	复杂几何、理论完善	天然守恒、激波 / CFD	光滑问题、谱精度
弱项	复杂几何、局部加密难	实现复杂、组装较重	通量构造复杂	复杂几何、间断 Gibbs

无论哪种方法：最终都得到有限维代数系统 —— 矩阵方程、ODE 系统或特征值问题

求解时间相关 PDE

Euler 迭代 · Runge–Kutta 迭代 · 操作分裂 · Newton 法

时间相关 PDE

先离散空间 $\rightarrow$ ODE 系统; 再用时间格式推进

$$\dot{\mathbf{u}}(t) = -\mathbf{A}\mathbf{u}(t) + \mathbf{b}(t) \quad (\text{FDM})$$

$$\mathbf{M}\dot{\mathbf{u}}(t) + \mathbf{K}\mathbf{u}(t) = \mathbf{b}(t) \quad (\text{FEM})$$

显式 Euler

$$\mathbf{u}^{n+1} = \mathbf{u}^n - \Delta t \mathbf{A}\mathbf{u}^n + \Delta t \mathbf{b}^n$$

条件稳定: $\Delta t \leq Ch^2$ 每步只需矩阵 $\times$ 向量

隐式 Euler

$$(\mathbf{I} + \Delta t \mathbf{A}) \mathbf{u}^{n+1} = \mathbf{u}^n + \Delta t \mathbf{b}^{n+1}$$

无条件稳定

每步解一个线性系统

Crank–Nicolson

$$\left(\mathbf{I} + \frac{\Delta t}{2} \mathbf{A}\right) \mathbf{u}^{n+1} = \left(\mathbf{I} - \frac{\Delta t}{2} \mathbf{A}\right) \mathbf{u}^n + \dots$$

无条件稳定, $O(\Delta t^2)$ 每步解一个线性系统

非线性 PDE: Newton 法反复求解线性系统

Navier–Stokes、反应扩散、Hamilton–Jacobi..... 离散后得到非线性方程组 $F(u) = 0$

在当前迭代点线性化，每步求解

$$\mathbf{J}(\mathbf{u}^{(k)}) \delta \mathbf{u}^{(k)} = -\mathbf{F}(\mathbf{u}^{(k)}), \quad \mathbf{J} = \frac{\partial \mathbf{F}}{\partial \mathbf{u}}$$
$$\mathbf{u}^{(k+1)} = \mathbf{u}^{(k)} + \delta \mathbf{u}^{(k)}$$

关键认识

非线性问题 $\Rightarrow$ 反复出现线性系统，只是每个 Newton 步的 “A” 都是新的 Jacobian

一族结构相近的线性系统从哪里来？

时间步进 $\times$ Newton 迭代 $\times$ 参数扫描

一个三维非线性参数化 PDE 数据集，可能需要解上百万个结构相近的线性系统

10^6

个相近线性系统

$Ax = b$ 线性代数求解器

稀疏矩阵 · Krylov 方法 · 多重网格 · 预处理器

离散后的矩阵：大而稀疏

- 稀疏性的本质：离散格式是局部的 —— 每个自由度只和邻近自由度耦合
- 矩阵的非零结构 = 网格 / 单元的邻接关系
- 第一原则：只存非零元，只对非零元做计算

COO

坐标三元组 (i, j, a_{ij})
适合矩阵组装阶段

CSR

按行压缩：值 / 列索引 / 行起始
适合矩阵-向量乘 $y = Av$

CSC

按列压缩（CSR 的列版本）
适合直接法分解 / 列操作

Krylov 最核心的操作

不是求 A^{-1} ，而是反复算 Av 。稀疏时只遍历非零元，复杂度 $O(\text{nnz}(A))$ 。
 workflow: COO 组装 $\rightarrow$ CSR $\rightarrow$ 迭代求解。

以 $n = 10^6$ 为例

10^{12}

稠密存储的元素个数

$\approx 10^7$

稀疏存储：每行约 5–10 个非零元， $O(n)$

相差 5 个数量级

直接法 vs 迭代法

	直接法	迭代法
思想	分解矩阵一次求解： $A = LU$	从 x_0 出发逐步逼近，看残差 $r_k = b - A x_k$
方法	LU、Cholesky	Jacobi、G-S、CG、GMRES
优点	精度高、鲁棒	内存低，适合大规模稀疏系统
缺点	填入 fill-in：因子不再稀疏	收敛依赖矩阵性质 → 需要预处理

停止准则： $\|r_k\|/\|b\| \leq \text{tol}$ ；注意病态系统中“残差小”不一定“误差小”

求解器选择原则

对称正定 SPD → **CG**

对称不定 → **MINRES**

一般非对称 → **GMRES / BiCGStab**

大规模 PDE → **Krylov + 预处理器**

Krylov 子空间方法

残差方程：解原问题 $\Leftrightarrow$ 解 $\mathbf{A} \mathbf{e}_0 = \mathbf{r}_0$

$$\mathbf{r}_k = \mathbf{b} - \mathbf{A} \mathbf{x}_k \quad \mathbf{r}_0 \text{ 包含当前误差的全部信息}$$

不在整个 $\mathbb{R}^n$ 中找解，而在低维子空间中找修正

$$\mathcal{K}_m(\mathbf{A}, \mathbf{r}_0) = \text{span}\{\mathbf{r}_0, \mathbf{A}\mathbf{r}_0, \dots, \mathbf{A}^{m-1}\mathbf{r}_0\}$$


$$\mathbf{x}_m \in \mathbf{x}_0 + \mathcal{K}_m(\mathbf{A}, \mathbf{r}_0)$$

- 不需要 $\mathbf{A}^{-1}$ ，甚至不必组装 $\mathbf{A}$ ，只要会算 $\mathbf{A} \cdot \mathbf{v}$
- 收敛速度由谱（特征值分布）决定：谱越集中收敛越快 $\rightarrow$ 预处理的意义

方法	矩阵类型
CG	对称正定（Poisson、扩散）
GMRES	一般非对称，最小化残差
MINRES	对称不定（鞍点）
BiCGStab	非对称，内存更省

GMRES 需存基向量 $\rightarrow$ 实际常用重启 GMRES(m)

多重网格：让每种频率的误差都被高效消除



1 经典迭代 = 光滑器


Jacobi / Gauss-Seidel 对高频误差几步压平，对低频误差几乎不动

2 换一个网格看误差

细网格上的低频误差，放到粗网格上“变得高频”又能被消除


3 递归 → V 循环

下行限制残差、最粗层直接解、上行延拓修正；复杂度最优 $O(N)$ ，迭代数几乎与 h 无关



光滑几步：高频被压平

GMG 几何
AMG 代数
(可作预处理)



V 循环：高频在细网格清理，低频在粗网格清理

- 1 偏微分方程传统数值方法
- 2 神经网络求解偏微分方程**
- 3 神经网络求解应用实例

传统数值方法问题

有限差分 / 有限元 / 有限体积的共同内核：离散化 —— 把连续时空切成网格，化为代数系统 $Ax = b$

①

网格生成

复杂几何（整车气动、航空发动机）的网格划分高度依赖经验、耗费人力；网格质量稍差即可能发散。

②

维数灾难

网格量随维度指数爆炸：三、四维尚可应付，金融定价、高维 Schrödinger 等数十维问题基本瘫痪。

③

不可复用

求解是一次性的：边界、系数或工况（如 Reynolds 数）一旦变化，就要重新划网格、重新求解。

神经网络的思路：直接绕开「离散化」这一前提 —— 在连续域上求解。


示例问题：微结构材料生成

结构决定性能：


组分材料相同，微结构不同




性质不同！




轻质



低热导



选择透过性




负泊松比




面向航空领域等需求，如何设计满足多目标要求的三维复杂微结构？




隐身飞机



特定波段无散射、各向同性、
轻质、高机械强度



调控不同组分空间分布



微结构


示例问题：微结构材料生成

- 力学性质: 材料本构关系

线性弹性 $\tau(r) = C(r) : \varepsilon(r)$

- 散射性质: 经典电磁理论

某些条件下散射强度正比于结构因子




微结构材料逆向设计：大幅提升满足特定需求的新材料研发效率！

- 发展跨尺度多物理场的智能求解

- 重构复杂离散微结构的逆向设计范式


- 揭示无序材料深层次“结构-性能”关系

- 赋能国家重大工程装备的材料革新



示例问题：微结构材料生成

正问题瓶颈



- 计算规模爆炸：
有限元等计算成本随规模非线性增长
- 重复求解成本：
组分变化每次需全新求解，无继承性

初始微结构



确定微结构散射、力学性质

散射、力学性质符合要求？

结束

反馈调节微结构

反问题瓶颈




- 计算规模爆炸：
离散优化计算成本随规模非线性增长
- 局部最优陷阱：
模拟退火等易陷入局部最优

根本原因：高维灾难

三维体系线性分辨率100时，包含 10^6 个体素，两组分体系构型数高达 $2^{1000000}$

神经网络特点：万能逼近



定理 4.1 – 通用近似定理 (Universal Approximation Theorem)

[Cybenko, 1989, Hornik et al., 1989]: 令 $\varphi(\cdot)$ 是一个非常数、有界、单调递增的连续函数, $\mathcal{I}_d$ 是一个 d 维的单位超立方体 $[0, 1]^d$, $C(\mathcal{I}_d)$ 是定义在 $\mathcal{I}_d$ 上的连续函数集合。对于任何一个函数 $f \in C(\mathcal{I}_d)$, 存在一个整数 m , 和一组实数 $v_i, b_i \in \mathbb{R}$ 以及实数向量 $\mathbf{w}_i \in \mathbb{R}^d$, $i = 1, \dots, m$, 以至于我们可以定义函数

$$F(\mathbf{x}) = \sum_{i=1}^m v_i \varphi(\mathbf{w}_i^T \mathbf{x} + b_i), \quad (4.33)$$

作为函数 f 的近似实现, 即

$$|F(\mathbf{x}) - f(\mathbf{x})| < \epsilon, \forall \mathbf{x} \in \mathcal{I}_d. \quad (4.34)$$


其中 $\epsilon > 0$ 是一个很小的正数。

隐藏层神经元的数量足够, 以任意的精度来近似任何从一个定义在实数空间中的有界闭集函数




微分方程解 $u(t, x)$ 本身就是坐标的连续函数 $\rightarrow$ 直接用 $u_\theta(t, x)$ 表示它
求解 = 求一组网络权重 θ , 任意坐标即时求值 $\rightarrow$ 无网格表示

无处不在的偏微分方程：




热传导方程

$$\frac{\partial u}{\partial t} = \kappa \Delta u$$




波动方程

$$\frac{\partial^2 u}{\partial t^2} = c^2 \Delta u$$



纳维-斯托克斯方程

$$\begin{cases} \frac{\partial \rho}{\partial t} + \nabla \cdot (\rho \mathbf{u}) = 0 \\ \rho \left(\frac{\partial \mathbf{u}}{\partial t} + (\mathbf{u} \cdot \nabla) \mathbf{u} \right) = \\ -\nabla p + \mu \Delta \mathbf{u} + (\lambda + \mu) \nabla (\nabla \cdot \mathbf{u}) + \rho \mathbf{f}. \end{cases}$$



薛定谔方程

$$i\hbar \frac{\partial \psi}{\partial t} = -\frac{\hbar^2}{2m} \Delta \psi + V\psi$$

现代深度学习框架：自动微分Autograd引擎

- 思想：用神经网络 $u_\theta(t, x)$ 来表示 $u(t, x)$

- 问题：如何计算微分




- 答案：Autograd!

$$\frac{\partial u}{\partial t} = \kappa \Delta u$$

$$\frac{\partial^2 u}{\partial t^2} = c^2 \Delta u$$

$$\begin{cases} \frac{\partial \rho}{\partial t} + \nabla \cdot (\rho \mathbf{u}) = 0 \\ \rho \left(\frac{\partial \mathbf{u}}{\partial t} + (\mathbf{u} \cdot \nabla) \mathbf{u} \right) = \\ -\nabla p + \mu \Delta \mathbf{u} + (\lambda + \mu) \nabla (\nabla \cdot \mathbf{u}) + \rho \mathbf{f}. \end{cases}$$

$$i\hbar \frac{\partial \psi}{\partial t} = -\frac{\hbar^2}{2m} \Delta \psi + V\psi$$



由此介绍三类工作

1

PINN 物理约束的单实例求解

把方程残差与初边值约束直接写入损失，在连续域上优化单个实例的解

2

算子学习 (DeepONet / FNO) 从“解函数”到“解算子”

学习函数空间到函数空间的映射：一次训练即可对整族参数瞬时求解，并能跨分辨率泛化（数据驱动天气预报即其代表性成功）

3

PINO 物理约束 + 算子学习

把 PDE 残差写回算子学习的训练目标，兼取二者之长

两处工程难点：

- ① 多项物理损失梯度尺度失衡 → 需自适应权重；
- ② 频谱偏置（先学低频）→ 激波 / 湍流等高频收敛慢，常用 Fourier 特征映射缓解

物理信息神经网络

Physics-informed neural networks

PINN: 把方程写进损失函数

处理参数化非线性 PDE (例: Burgers $\mathcal{N}[u; \lambda] = \lambda_1 u u_x - \lambda_2 u_{xx}$) ; 正问题求 u , 反问题反推 λ

$$u_t + \mathcal{N}[u; \lambda] = 0, \quad x \in \Omega, t \in [0, T]$$

网络近似 + 自动微分得残差

$$f_\theta(t, x) := \partial_t u_\theta + \mathcal{N}[u_\theta]$$

若 u_θ 为真解, 则处处 $f_\theta \equiv 0 \rightarrow$ 写进损失

$$\text{MSE} = \frac{1}{N_u} \sum_{i=1}^{N_u} |u_\theta(t_u^i, x_u^i) - u^i|^2 + \frac{1}{N_f} \sum_{i=1}^{N_f} |f_\theta(t_f^i, x_f^i)|^2$$

MSE_u : 初边值 / 观测拟合

MSE_f : 配点上的方程残差 (配点不需要真解标签)

PINN 的关键一步:

把自动微分从“对参数求导以训练网络”扩展到“对坐标求导以表达物理方程”
 MSE_f 既是物理正则化, 也是连续时空上的残差约束


PINN连续时间模型：一个网络表示整个时空

- 网络输入 (t, x) , 输出 $u_\theta(t, x)$: 无需显式时间推进、不依赖网格格式
- 损失 = $MSE_u + MSE_f$, 配点散布在整个时空域

算例：非线性 Schrödinger (周期边界, 复值解)

$$i h_t + 0.5 h_{xx} + |h|^2 h = 0, \quad h = u + i v$$

双输出网络同时表示实部 u 与虚部 v ; 损失 = $MSE_0 + MSE_b + MSE_f$
 $N_0 = 50$ 、 $N_b = 50$ 、 $N_f = 2 \times 10^4 \rightarrow$ 相对 L^2 误差 $\approx 1.97 \times 10^{-3}$



代价：要充分约束残差，配点数随维度指数爆炸 —— 这正是下面离散时间模型要缓解的问题

PINN离散时间模型：把隐式 RK 编进网络

只固定相邻两层 t^n 与 t^{n+1} ，网络只以空间坐标 x 为输入，时间交给 q 级 RK

q 级 Runge–Kutta：网络一次输出 $q + 1$ 个函数 $[u^{n+c_1}(x), \dots, u^{n+c_q}(x), u^{n+1}(x)]$

$$u^{n+c_i} = u^n - \Delta t \sum_{j=1}^q a_{ij} \mathcal{N}[u^{n+c_j}], \quad u^{n+1} = u^n - \Delta t \sum_{j=1}^q b_j \mathcal{N}[u^{n+c_j}]$$

关键一步：把每个 RK 方程反解出起点 u^n

$$u_i^n := u^{n+c_i} + \Delta t \sum_{j=1}^q a_{ij} \mathcal{N}[u^{n+c_j}] \Rightarrow u^n = u_i^n, \quad i = 1, \dots, q+1$$

$$\text{SSE} = \sum_{i=1}^{q+1} \sum_x |u_i^n(x) - u^n(x)|^2$$

起点 u^n 是已知快照 $\rightarrow q + 1$ 个重构量都应贴合同一份数据：物理约束被硬编码进网络

算例：Allen–Cahn方程单步跨越

$$\begin{aligned} u_t - 0.0001 u_{xx} + 5u^3 - 5u &= 0 \\ u(0, x) &= x^2 \cos(\pi x), \\ u(t, -1) &= u(t, 1), \\ u_x(t, -1) &= u_x(t, 1). \end{aligned}$$

$q = 100$ 级隐式 Gauss–Legendre
单步 $\Delta t = 0.8$ 从 $t=0.1$ 跨到 0.9

$$O(\Delta t^{2q}) = 0.8^{200} \approx 10^{-20}$$

时间误差远低于机器精度； L^2 误差 $\approx 6.99 \times 10^{-3}$

PINN反问题：数据驱动发现 PDE

参数 λ 不再已知，而是与网络参数 θ 一同优化 —— 物理约束下的系统辨识


二维 Navier-Stokes 圆柱绕流 (Re=100)

$$u_t + \lambda_1(uu_x + vu_y) = -p_x + \lambda_2(u_{xx} + u_{yy})$$

$$u = \psi_y, \quad v = -\psi_x \Rightarrow u_x + v_y = 0$$

流函数 ψ 使不可压条件自动成立；训练数据只含速度、无压力

λ_1 、 λ_2 误差仅 0.08% / 4.67% (对 1% 噪声稳健)，并在无压力标签下重建整个压力场



统一框架

同一套“残差 + 数据”损失同时覆盖：正问题 / 反问题 × 连续时间 / 离散时间 —— PINN 既是求解器，也是辨识方法

PINN 小结：单实例求解器的边界

PINN = 神经网络替代 + 自动微分得到的方程残差损失 → 物理约束下的单实例求解器

局限

- 换一个初值、系数或边界，通常就要重训一个网络
- 连续模型依赖大量配点，高维代价高；损失各项权重敏感
- 高阶导数、多尺度、长时间问题优化困难
- 整个优化非凸，缺乏全局收敛保证

下一步

把学习对象从

解函数 → **解算子**

一次训练，整族 PDE 瞬时求解：
DeepONet 与 FNO 两条路线

神经算子网络

DeepONet · FNO

DeepONet: 从算子万能逼近定理出发

学习算子 G : 输入函数 u (在 m 个固定传感点采样) + 查询点 $y \rightarrow$ 输出 $G(u)(y)$

注: 这边的符号 u 和 PPT 中的其他 u 不一致, 属于误用, 最好改为 a 。

算子万能逼近定理 (Chen & Chen): 单隐层网络即可任意精度逼近非线性连续算子

$$G(u)(y) \approx \sum_{k=1}^p \left[\sum_{i=1}^n c_i^k \sigma \left(\sum_{j=1}^m \xi_{ij}^k u(x_j) + \theta_i^k \right) \right] \sigma(w_k \cdot y + \zeta_k)$$


branch: 只依赖采样值 $[u(x_1), \dots, u(x_m)]$

trunk: 只依赖查询点 y

- 函数 u 是无穷维对象 $\rightarrow$ 用固定传感点上的取值离散表示 (点可非规则, 但对所有 u 必须一致)
- 输出查询点 y 的位置与数量不作任何限制 —— “尽可能弱的假设”
- 定理只管逼近误差 (存在性), 不管优化与泛化; DeepONet 的贡献是把它落地成易训练的架构

branch-trunk 架构：系数 × 基函数

$$G(u)(y) \approx \sum_{k=1}^p \left[\sum_{i=1}^n c_i^k \sigma \left(\sum_{j=1}^m \xi_{ij}^k u(x_j) + \theta_i^k \right) \right] \sigma(w_k \cdot y + \zeta_k)$$




stacked: p 个小 branch 网各输出一个 b_k ;
unstacked: 单个 branch 网一次输出整个向量

视角:

- trunk 输出 = 一组学到的基函数
- branch 输出 = 由输入 u 决定的系数

trunk 张成与 u 无关的子空间, branch 在其中“挑选”输出函数



DeepONet 训练数据

一个数据点 = 三元组


$$(u, y, G(u)(y))$$

同一条输入轨迹 u 配不同的 y 可生成多个数据点：100 条 $u \times$ 各 100 个 $y = 10^4$ 个点

输入函数空间：从哪采样 u ?

$$k_l(x_1, x_2) = \exp(-\|x_1 - x_2\|^2 / 2l^2)$$

高斯随机场 GRF (RBF 核)：长度尺度 l 越大，函数越光滑；
另一类：Chebyshev 正交多项式张成的函数空间



GRF 采样的随机光滑输入函数

参考解 (标签) 由数值求解器生成：ODE 用 Runge-Kutta(4,5)，PDE 用二阶有限差分

从固定基到可学习基

“系数 × 基函数”正是传统数值方法的经典范式 $u(y) \approx \sum c_k \phi_k(y)$

FEM

局部帽状基（分片多项式）
系数 = 节点取值

谱方法

全局光滑基（Fourier / Chebyshev）
系数 = 谱系数

DeepONet

从数据学出的自适应基 $t_k(y)$
branch 一次前向给出系数 b_k

两点本质差别：1) 基从数据中学出（贴合解流形）；2) 经典方法对每个新问题都要解方程组定系数，DeepONet 一次前向即可

关键实验结论

- 泛化误差远小于直接拼接输入的 FNN —— 强 inductive bias 来自 branch / trunk 分而治之
- 小数据区测试误差呈指数收敛 $\propto e^{-x/k}$ （深度学习中首次观测到）；大数据区转为多项式率
- 输入越不光滑（GRF 长度尺度 l 越小）所需传感点越多： $m \propto 1/l$

FNO: 学习函数空间之间的映射

Neural Operator 算子网络

学习对象：一族 PDE 的解算子（而非有限维向量映射）

$$\mathcal{G}^\dagger : \mathcal{A} \rightarrow \mathcal{U}, \quad a \mapsto u$$

与 PINN 的根本区别

PINN 学单实例的解函数，换实例重训
FNO 训练一次，新输入只需一次前向传播

三个任务对应不同的输入-输出函数对

- Darcy Flow: 系数场 $a(x) \mapsto$ 解 $u(x)$ (算子非线性!)
- Burgers: 初值 $u_0(x) \mapsto$ 末态 $u(x, 1)$
- Navier-Stokes: 涡量历史 $w|[0,10] \mapsto$ 未来 $w|(10, T]$

loss: 函数范数

$$\|\mathcal{G}_\theta(a_j) - u_j\|_{L^2(D)}^2 = \int_D |\mathcal{G}_\theta(a_j)(x) - u_j(x)|^2 dx.$$


理论上是函数范数

data loss: 离散点上的 L^2

$$\mathcal{L}_{\text{data}} = \frac{1}{B} \sum_{j=1}^B \frac{1}{n} \sum_{i=1}^n |\mathcal{G}_\theta(a_j)(x_i) - u_j(x_i)|^2$$

实现中是离散求和（纯 FNO 的 loss 不含 PDE 残差）

神经算子的一般结构与核心难点



算子层 = 局部线性 W + 非局部积分核 $\mathcal{K}$ + 逐点非线性

$$v_{t+1}(x) = \sigma(W v_t(x) + (\mathcal{K} v_t)(x))$$

$$(\mathcal{K} v)(x) = \int_D \kappa(x, y) v(y) dy \Rightarrow O(n^2)$$


难点在这个积分

$$(\mathcal{K} v)(x_i) \approx \sum_{j=1}^n \kappa(x_i, y_j) v(y_j) w_j, \quad i = 1, \dots, n$$

n 个离散点上是对所有点对的双重求和, 存与算都是 $O(n^2)$, 细网格上不可承受


路线	对积分的处理	复杂度	网格
GNO	邻域 / 图 + 消息传递	$O(n^2)$ (截断后更低)	任意
低秩 LNO	可分离核 $\sum \varphi_r(x) \psi_r(y)$ (即 unstacked DeepONet)	$O(nR)$	任意
MGNO	近场 + 远场层次分解 (仿快速多极)	$\approx O(n)$	任意
FNO	平移不变核 $\rightarrow$ 卷积 $\rightarrow$ FFT 频域乘法	$O(n \log n)$	均匀规则

Fourier 层：积分 $\rightarrow$ 卷积 $\rightarrow$ 频域乘法



关键简化：令核平移不变，积分退化为卷积

$$\kappa(x, y) = \kappa(x - y) \Rightarrow (\mathcal{K}v)(x) = (\kappa * v)(x)$$




卷积定理 $\rightarrow$ 频域逐模态相乘

$$\hat{v}_{t+1}(k) = R(k) \hat{v}_t(k), \quad R(k) \in \mathbb{C}^{d_v \times d_v}$$

Fourier Layer (FNO 核心公式)：直接把频域线性变换 R 当作可学习参数，绕过物理空间的核

$$v_{t+1}(x) = \sigma(W v_t(x) + \mathcal{F}^{-1}(R \cdot \mathcal{F}(v_t))(x))$$

一层的计算流程



Fourier 分支负责全局信息交换，局部分支 W 保留逐点与非周期边界信息；实践中 $k_{\max} = 12$ 即足以应付大部分任务


截断低频为何仍有效

只学 12 个模态，高频从哪来？

单层线性变换只搬运低频，但逐点非线性与解码器 Q 能重新生成高频分量。

谱分析：简单截断 20 模态误差 $\sim 2\%$ ，FNO 用 12 个参数化模态即 $\leq 1\%$

zero-shot 超分辨



参数 $R(k)$ 学在 Fourier 空间、基函数定义在连续域 $\rightarrow 64^2$ 训练, 256^2 直接评估不退化

复杂度：FFT 主导, $O(n \log n)$ (朴素积分核 $O(n^2)$) —— 代价是 FFT 强制要求等距均匀网格

不规则网格的三条出路（理论不挑网格，实现挑）

插值：先插到规整矩形网格，跑完再插回；引入额外误差

Geo-FNO：多学一个坐标变换：把物理网格映到均匀隐空间再做 FFT

退回 GNO：网格看成图、消息传递；最灵活但退化到 $O(n^2)$

FNO 实验：Navier–Stokes 推理加速

二维不可压 NS (涡量形式)：学习 “涡量历史 $\mapsto$ 未来涡量”

$$\partial_t w + u \cdot \nabla w = \nu \Delta w + f, \quad w = \nabla \times u$$

$$w|_{(0,1)^2 \times [0,10]} \longmapsto w|_{(0,1)^2 \times (10,T]}$$

FNO-2D：空间二维算子 + 时间递推

自回归式逐步向前推进；更混沌 (ν 小) 或数据稀缺时往往更稳

FNO-3D：直接做时空三维 Fourier 算子

一次输出整段未来；数据充足时精度最佳

0.005s vs 2.2s

反问题中单次前向传播 vs 拟谱求解器 —— 约 440 $\times$ 加速；
这正是 “需要反复求解 PDE” 场景 (反演、PDE 约束优化) 的价值所在

两条算子学习路线：DeepONet vs FNO

	DeepONet	FNO
理论根基	算子万能逼近定理	离散收敛（随网格加密收敛到连续算子）
逼近方式	可分离核 $\sum b_k(u) t_k(y)$ ：基由数据学出	固定 Fourier 基上学频域乘子 $R(k)$
输入表示	固定传感点（可非规则，但对所有 u 一致）	任意分辨率网格（FFT 要求等距均匀）
输出求值	trunk 可在任意位置查询（mesh-free）	输出落在整张网格上
分辨率	改 sensor 需重训 / 插值；输出端连续	输入输出皆分辨率不变，zero-shot 超分辨

互补：散乱 / 非规则输出、任意点查询 → DeepONet；规则网格、超分辨与时空外推 → FNO

物理信息神经算子网络

$\text{PINO} = \text{FNO 骨干} + \text{PINN 式残差损失}$

PINO = FNO 骨干 + PINN 式残差损失

方法	学习对象	主要监督信号
PINN	单个解函数 $u_{\theta}(x, t)$	PDE loss
DeepONet	解算子 (branch-trunk)	data loss
FNO	解算子 (Fourier 层)	data loss
PINO	物理约束的解算子	data loss + PDE loss

补两者的短板

- PINN：不一定要数据，但单实例、难优化
- FNO：求解极快、跨分辨率，但纯数据驱动、分布外失准
- PINO：数据帮助优化 + 物理提升一致性与高分辨泛化

关键差别

PINO 不是“用神经网络解一个 PDE”，而是“用物理约束去学习一族 PDE 的解算子”：残差施加在整族输出 $\{G_{\theta}(a)\}$ 上，而非单个解函数上

两类学习对象

无论哪类，学的都是整个映射 $\mathcal{G}_\theta(a)$ ，而非单个解 u

稳态问题

$$\mathcal{P}(u, a) = 0 \text{ in } D, \quad u = g \text{ on } \partial D$$

$$\mathcal{G}^\dagger : a \mapsto u$$

典型：Darcy 方程 $-\nabla \cdot (a \nabla u) = f$ ，输入系数场，输出稳态解

动力系统

$$\frac{du}{dt} = \mathcal{R}(u), \quad u(0) = a$$

$$\mathcal{G}^\dagger : a \mapsto u|_{(0, T]}$$

典型：Burgers 与 Navier–Stokes，输入初值，输出整段时间轨迹

与上篇的衔接

这两类问题正对应上篇的“静态线性 $A x = b$ ”与“时间相关 $M \dot{u} + K u = b$ ”：

传统路线对每个参数 a 都要重新组装求解；PINO 把整族“参数 $\rightarrow$ 解”的映射一次性学下来

训练目标：数据项 + PDE 项

算子层面的两类损失与总目标

$$\mathcal{J}_{\text{data}} = \mathbb{E}_{a \sim \mu} [\|\mathcal{G}_{\theta}(a) - \mathcal{G}^{\dagger}(a)\|^2], \quad \mathcal{J}_{\text{pde}} = \mathbb{E}_{a \sim \mu} [\mathcal{L}_{\text{pde}}(a, \mathcal{G}_{\theta}(a))]$$
$$\min_{\theta} \mathcal{J}_{\text{data}}(\mathcal{G}_{\theta}) + \lambda \mathcal{J}_{\text{pde}}(\mathcal{G}_{\theta})$$

为什么是 semi-supervised

- PDE 损失只需采样输入实例 $a \sim \mu$ 与配点，按残差 $|\mathcal{P}(\mathcal{G}_{\theta}(a), a)|^2$ 计算，**不需要真解标签** → 可无限采样“虚拟实例”
- 少量带标签数据 + 无限物理监督 = 半监督算子学习；
- 完全无标签则接近物理自监督

训练方式：coarse data + fine physics

数据损失在粗网格、PDE 损失在细网格：

粗数据提供稳定监督；

细网格残差补上数据未覆盖的高频物理。

两阶段框架：先学算子，再按实例微调

1

阶段一：operator learning

学 $\mathcal{G}_\theta: a \mapsto u$ —— 可只用数据、只用 PDE、或二者结合；虚拟实例可无限采样

2

阶段二：instance-wise fine-tuning

对给定 a ，以 $\mathcal{G}_{\theta_0}(a)$ 为初值用 PDE 损失继续微调；anchor loss 把模型钉在已学解附近：

$$\mathcal{L}_{\text{pde}} + \alpha \mathcal{L}_{\text{op}}, \quad \mathcal{L}_{\text{op}} = \|\mathcal{G}_{\theta_i}(a) - \mathcal{G}_{\theta_0}(a)\|^2$$

为什么 PINO 比 PINN 容易优化

- PINN 是点态拟设：从随机函数出发，靠残差把初边值信息传播到整个时空，长时间、多尺度时极难
- PINO 的拟设是算子：已学到这族 PDE 的解空间结构，新输入的 $\mathcal{G}_\theta(a)$ 本身就是良好初值 —— 在解流形附近微调

0.9% vs 18.7%

Kolmogorov flow (Re=500) 误差：
PINO 微调 vs PINN，且快约 25×

神经算子怎么求导

方法	做法	特点
数值微分	把输出当数组，有限差分 / Fourier 差分	快、省显存；有截断误差、依赖网格
逐点 autograd	把输出写成 $x \mapsto u(x)$ 后逐点自动微分	通用、精确；慢且显存大
function-wise (推荐)	Fourier 表达 + 链式法则，一次性求整场导数	对有限 Fourier 表示精确且高效

Fourier 微分：每个模态乘频率因子，一次求出整场导数

$$v_x(x) = \sum_m \frac{i2\pi m}{D} \hat{v}_m e^{i2\pi m x/D}, \quad v_{xx}(x) = \sum_m -\left(\frac{2\pi m}{D}\right)^2 \hat{v}_m e^{i2\pi m x/D}$$
$$u_x(x) = Q'(v_L(x)) \sum_m \frac{i2\pi m}{D} \hat{v}_L(m) e^{i2\pi m x/D}$$

非周期边界 → Fourier continuation：直接 FFT 会把区间两端强行接起、产生 Gibbs 振荡。做法：对输入零填充到更大周期区域，网络在 padding 区自行生成平滑延拓（输出不强制为零），损失只在原区域计算。

实验：粗数据 + 细物理

固定低分辨率数据训练，在更高分辨率上施加 PDE 损失，测试跨分辨率泛化（相对误差）

问题	训练设置	原分辨率	2×	4×
Burgers	仅数据	0.32%	3.32%	3.76%
	数据 + PDE	0.17%	0.28%	0.38%
Darcy	仅数据	5.41%	9.01%	9.46%
	数据 + PDE	5.23%	1.56%	1.58%
Kolmogorov	仅数据	8.28%	8.27%	8.30%
	数据 + PDE	6.04%	6.02%	6.01%

更多结论

- 少数据乃至无数据：Darcy 上 PINO 无数据 1.50%，已接近有数据的 1.22%（DeepONet 6.97%）
- 长时间 transient flow：纯 PDE 从零训练误差 >50%；算子 ansatz + 微调 → 1.84%，且保持 ~400× 加速
- 逆问题：inverse model 误差 2.29%、系数准确率 97.1%，比 MCMC 快 ~3000×

PDE 损失不是普通正则项：它在高分辨率上补充了数据未覆盖的物理信息

PINO 用于逆问题：由解反推系数

Darcy flow: 观测到解 $u^\dagger$, 反推系数场 $a^\dagger$ —— 逆映射本身病态

路线一 forward model: 先学正向算子 $\mathcal{G}_\theta : a \mapsto u$, 再优化候选 $\hat{a}$

$$\mathcal{J}_{\text{forward}} = \mathcal{L}_{\text{pde}}(\hat{a}, u^\dagger) + \mathcal{L}_{\text{data}}(\mathcal{G}_\theta(\hat{a}), u^\dagger) + \mathcal{R}(\hat{a})$$

路线二 inverse model: 直接学逆算子 $\mathcal{F}_\theta : u \mapsto a$, 再加 PDE / anchor / 正则

$$\mathcal{J}_{\text{backward}} = \mathcal{L}_{\text{pde}}(\mathcal{F}_\theta(u^\dagger), u^\dagger) + \mathcal{L}_{\text{op}} + \mathcal{R}(\mathcal{F}_\theta(u^\dagger))$$

实验: inverse model 更优

输出 u 误差 2.29%、系数分类准确率 97.10% (forward: 6.43% / 95.38%)
比 MCMC 快约 3000×

PDE 损失的作用

纯网络易给出“看似匹配数据、却不满足方程”的解；PDE 损失把候选解钉在物理可行流形上

PINO 的局限

- instance-wise fine-tuning 仍依赖梯度下降，未必如直接用更细网格的传统求解高效
- 提高 PDE 损失分辨率可降截断误差，但增加成本、也可能使优化不稳
- 标准 FNO 更适合规则网格与简单区域：复杂几何需结合 graph operator 或几何编码

总结对比：

特征	PINN	DeepONet	FNO	PINO
核心思想	单实例求解器：求解一个特定的方程设定	branch-trunk：学习输入参数与解之间的关系	谱求解器：在频域（FFT）中学习全局映射	混合范式：FNO 架构 + PINN 训练策略
输入 → 输出	$(x, y, z) \rightarrow u$	$C(r) + (x, y, z) \rightarrow u$	场 $C(r) \rightarrow u(r)$	场 $C(r) \rightarrow u(r)$
训练数据	零（仅 PDE 残差）	多（FEM 数据对）	多（FEM 数据对）	零或少量
是否需重训	每换一个几何 / 工况都要	否	否	否
关键优势	实现简单；天然适合反问题	输入输出位置灵活	速度快；分辨率不变	速度 + 物理一致性
适用场景	校验单个设计	通用算子学习	有数据的力学 / 流场问题	需反复求解的优化闭环

选型逻辑：单个实例 / 反问题 → PINN；有大量数据、要快 → DeepONet / FNO；少数据 + 要物理保证 + 反复求解 → PINO

- 1 偏微分方程传统数值方法
- 2 神经网络求解偏微分方程
- 3 神经网络求解应用实例**

什么样的问题值得换上神经网络?

上一章给了四件工具(PINN / DeepONet / FNO / PINO), 应用的关键不是「能不能」, 而是问题本身有没有下面四个信号:

1

同族方程反复求解

参数扫描、设计优化、不确定性量化、实时预报 —— 训练一次, 成本被成千上万次调用摊销

算子学习 FNO / DeepONet

2

维数太高, 网格失效

金融定价、随机控制、多体量子 —— 网格数随维数指数爆炸, $d \geq 10$ 即瘫痪

采样型方法 Deep BSDE / VMC

3

有数据, 缺完整模型

观测稀疏含噪、边界 / 系数未知, 方程残差当正则, 数据与物理互补

PINN 反问题 / 数据同化

4

毫秒级响应要求

数字孪生、在线控制、交互式设计, 传统求解的小时级延迟进不了闭环

代理模型 一次前向推理

天气预报：每天都在求解的PDE

支配方程：大气原始方程组

动量方程 旋转球面上的 Navier–Stokes(科氏力)

连续性方程 质量守恒

热力学方程 能量守恒 + 加热源汇

水汽方程 相变 · 云 · 降水

强非线性 · 多尺度耦合 · 混沌(初值敏感) + 辐射 / 对流等次网格过程需参数化

传统数值预报(NWP)业务流水线



每天 4 次循环滚动; 「数值积分」一步就要在超级计算机上跑约一小时

~10⁹

全球网格自由度量级
(格点 × 层 × 变量)

小时级

单次确定性预报
超算耗时

×51


集合预报成员数
(成本再乘一倍量级)

同一组方程，每天换初值反复求解，是「学习解算子」的理想靶场: 把 **初始大气状态** → **未来状态** 当作一个算子，从 40 年历史数据中学出来

数据基座 ERA5: ECMWF 用同一套物理模式 + 资料同化「重放」1979 年以来的全球大气(0.25° 再分析)

FourCastNet: 第一个跑到 0.25° 的 AI 全球预报

- 骨干 AFNO: 把 FNO 的频域全局混合塞进 Transformer 的 token 混合层 —— 正是第二章 Fourier 层的直系后代
- 训练: ERA5 再分析约 40 年, 0.25° (≈ 25 km) 分辨率, 数十个大气变量
- 推理: 自回归 6 小时步进, 滚动外推到 7–10 天



学习目标: t 时刻全球场 $\mapsto t + 6h$ 全球场 (示意)

$u(t) \rightarrow \text{AFNO} \rightarrow u(t + 6h) \rightarrow \text{AFNO} \rightarrow \dots$

0.25°

首个达到再分析
原生分辨率的 AI 模型

$\sim 45,000\times$

论文报告的推理加速
(对比传统 NWP)


秒级

单次全球预报
(单 GPU 量级)


意义: 「纯数据驱动 + 算子结构」在天气预报中的潜力, 能耗与算力比超算数值积分低若干数量级

可实现未来6小时、24小时的短期和中期降水预报


Global precipitation forecasts for a 6-hour period
6小时累积降水



Global precipitation forecasts for a 24-hour period
24小时累积降水




在40年全球气象数据基础上，增加10年卫星降水数据



- 华为云登上 Nature 的第一个 AI 天气模型
- 3D Earth-Specific Transformer: 把「经度 × 纬度 × 13 个气压层」当作三维体数据切 patch，配地球特定的位置偏置
- 确定性指标(如 Z500 RMSE)全面优于 ECMWF IFS 业务确定性预报
- 台风路径等高影响天气的预报误差同样更小

工程仿真：在设计循环里CFD 是最慢的那一环

气象是「同一方程换初值」；工程设计是「同一方程换几何 / 参数」




气动外形：从翼型到整车，实时预测升阻力

- 难点：几何不规则、网格非结构 —— 标准 FNO 依赖规则网格上的 FFT，不能直接套用
- Geo-FNO(Li et al., 2022)：学一个坐标变换,把不规则物理域拉直成规则隐空间，在隐空间做 FFT，再变换回来
- 训练标签来自 CFD 高保真解；推理时新翼型毫秒级出压力分布

从学术到工业级数据集

- DrivAerNet++：约 8000 个参数化整车几何 + 高保真 CFD，专为训练气动代理而建
- 意义：整车气动评估从过夜跑一版变成拖动滑块实时看 Cd
- 离线用 CFD 造数据，在线用代理进设计循环



翼型绕流压力 / 速度场:几何 $\mapsto$ 流场(示意)

ms 级

单个外形
气动响应预测

8,000+

DrivAerNet++
开源整车样本


可微

外形参数可导
 $\rightarrow$ 梯度优化

一句话：气动设计是「同族 PDE 换几何反复解」的典型 —— 算子学习把工程师从等待求解器中解放出来,把时间还给设计本身。

微结构材料生成

正问题瓶颈



- 计算规模爆炸：
有限元等计算成本随规模非线性增长
- 重复求解成本：
组分变化每次需全新求解，无继承性

初始微结构



确定微结构散射、力学性质

散射、力学性质符合要求？

结束

反馈调节微结构

反问题瓶颈




- 计算规模爆炸：
离散优化计算成本随规模非线性增长
- 局部最优陷阱：
模拟退火等易陷入局部最优

根本原因：高维灾难


三维体系线性分辨率100时，包含 10^6 个体素，两组分体系构型数高达 $2^{1000000}$

微结构材料生成





跨尺度力学性能 高效正演



多目标离散结构 逆向生成




深层次构效关系 解析验证




微结构材料生成

物理信息算子神经网络学习物理规律




指标	有限元	仅物理监督	+ 有限元标签
K 平均误差	—	2.6 %	2.1 %
G 平均误差	—	4.3 %	3.5 %
推理速度, 128 ³ 样本	≈ 51 min	≈ 0.3 s	≈ 0.3 s
速度提升	1×	~10 ⁴ ×	~10 ⁴ ×

梯度信息反向传播引导微结构生成



设计新型离散扩散生成神经网络



将物理算子与生成优化统一为“可微闭环”，重构异质微结构材料智能反演范式

湍流：DNS 成本过高，机器学习建模闭包


为什么直接数值模拟(DNS)不可行

要分辨最小涡(Kolmogorov 尺度), 网格总量随雷诺数约按 Re^3 增长。真实飞机 / 汽车 $Re \sim 10^6-10^7$, DNS 所需算力远超任何超算, 工程实践中不采用 DNS。

工程折中: 只解大尺度(RANS / LES)。小尺度对大尺度的作用以「湍流闭包模型」近似, 而闭包正是长期以来主要的经验性来源。

机器学习闭包：用数据替经验公式

- 思路：从少量 DNS / 高保真数据, 学 “未解析应力 $\mapsto$ 可解析量” 的映射, 替换 RANS/LES 中的经验闭包
- 关键约束：将伽利略不变性、旋转不变性嵌入网络结构, 引入物理对称性以提升外推稳定性
- Kochkov et al.(PNAS 2021): ML 加速的 CFD 在 $8-10\times$ 粗网格上达到精细网格精度, 等效约 $40-80\times$ 加速




二维湍流涡量场:多尺度结构是闭包建模的核心难点

风险提示

- 长时间积分易累积漂移, 可能违反能量守恒
- 训练雷诺数 / 几何之外, 外推往往失效
- 稳健路线: ML 闭包与传统求解器混合, 而非完全黑箱

流场重建：由可观测量反演不可观测量

- 场景：实验中仅能获取染料 / 烟雾 / 温度的浓度场,无法直接获取速度,亦无法测量压力
- **Hidden Fluid Mechanics(Raissi et al., Science 2020)**：将可见浓度场输入 PINN,以 Navier-Stokes 作为残差约束,反解出隐藏的速度场与压力场
- 无需边界条件、无需压力测量,由物理方程本身补足缺失信息
- 典型反问题 / 数据同化：PINN 主攻反问题



可见标量(染料)浓度场 —— PINN 的唯一输入

为什么 PINN 在这里特别合适


数据稀疏、含噪且模型部分已知，方程残差既作为正则化抑制噪声，又可推算未观测的物理量。此类问题缺乏大批量标签，算子学习并不适用。



应用面：粒子成像测速器实验数据补全、无法布置压力传感器的场合，观测残缺而物理已知的情形，PINN 均为首选方法

碳封存：四维两相流，单次注入模拟由小时级降至秒级

- 问题:把 CO₂ 注入地下盐水层,预测几十年内羽流如何运移 —— 地下两相流达西方程,呼应第二章 Darcy 实验
- 挑战:三维 + 时间的四维场,且压力在井附近变化极陡、远场平缓,尺度跨度极大
- Nested FNO(Wen et al., 2023): 多级嵌套的傅里叶神经算子,由粗到细逐级聚焦井周高梯度区



CO₂ 羽流随时间运移:三个时刻的饱和度场(示意)

学习目标:注入参数 / 地质 $\mapsto$ 全时空饱和度 + 压力场

$\sim 7 \times 10^5$

对比传统求解
的加速量级

1.8% / 0.5%

饱和度 / 压力
相对误差

2 年 $\rightarrow$ 2.8 s


30 年注入的概率化
评估: 从两年到秒级

加速换来了什么:不确定性量化

封存安全评估需评估上千种地质 / 注入情景。传统模拟逐一计算需数年;代理将单次成本降至秒级,蒙特卡洛式风险评估首次变得可行,充分体现了同族方程反复求解的优势。

方法注脚: 嵌套 / 多分辨率是算子学习应对极端多尺度的通用方法,与气象中 GraphCast 的多重网格、数值方法中的多重网格(第一章)原理相通:在不同尺度上分别配置算力。

地震成像：全波形反演，PDE 约束的优化问题



层状速度模型 + 地震波前传播(示意)

数学形式:带 PDE 约束的最优化

$$\min_c \| F(c) - d \|^2$$

c : 地下速度模型 d : 地表实测地震记录 F : 解波动方程的正演算子

为什么传统 FWI 极其昂贵

- 每次梯度迭代 × 每一炮，都要解一次三维波动方程
- 强非凸，易因周期跳跃陷入局部极小，对初值高度敏感

AI 的三种切入方式

1 代理正演

用神经算子替代波动方程正演 F , 将每次迭代的多炮求解替换为一次推理


2 端到端反演

直接学「地震记录 $\mapsto$ 速度模型」的逆映射
(InversionNet; OpenFWI 开源基准)

3 Eikonal-PINN

用 PINN 解程函方程算走时，做初至层析，缓解周期跳跃

核聚变：从等离子体模拟到毫秒级实时控制



托卡马克 D 形磁面截面(示意)

物理:多场强耦合的难点

- 平衡:Grad-Shafranov 方程(磁面位形)
- 稳定性 / 演化:磁流体力学(MHD)
- 输运:湍流驱动的热 / 粒子输运

代理加速模拟

QLKNN 等用神经网络替代昂贵的湍流输运计算,将回路内的物理评估加速若干数量级,支撑实时仿真。

破裂预测

等离子体破裂会瞬间损毁装置。深度学习从诊断信号预测破裂风险(Nature 2019), 为提前干预争取时间

强化学习实时控制磁场

DeepMind × EPFL, Nature 2022

- 在 TCV 托卡马克上,用强化学习直接操控 19 个控制线圈的电压
- 把等离子体约束并塑造成多种目标位形(含「水滴」等奇异形状)
- 控制回路要求毫秒级响应,传统逐步求解器无法满足

闭环范式: 代理提供快速求解,强化学习负责决策;两者结合,使 AI 首次进入聚变实时控制回路。

要点: 这是「PDE 代理 + 控制」的范式跃迁: 其意义不仅在于加速方程求解, 更在于将求解速度转化为实时决策能力, 使 AI 直接参与物理装置的运行。


血流动力学：由有创测量转向无创推算

临床动机：FFR 与冠脉狭窄

血流储备分数(FFR)是判断冠脉狭窄是否需要支架的金标准，但需将压力导丝插入血管，属有创操作，存在风险且成本高。能否仅凭影像实现无创评估？

PINN 融合影像与物理

- 输入：4D-Flow MRI 测到的稀疏含噪速度场
- 约束：Navier-Stokes 残差，以物理补全 MRI 测量不准或无法测量的部分，并直接推算压力
- 输出：无创的血管内压力与壁面剪切应力
- 代表工作：Kissas et al.(2020)用 PINN 做动脉血流与压力预测



为什么是 PINN 而非纯代理

每位患者的血管几何不同、数据稀疏,缺乏海量同分布标签以训练算子。PINN 以「单例 + 物理约束」求解,天然契合个体化、数据受限的临床场景。商业先例如 HeartFlow 已将类似思路用于无创 FFR 评估。

监管与安全底线: 医疗场景对错误零容忍,模型必须经临床验证、给出不确定度,并接受医生复核。AI 在此为辅助决策,而非替代诊断。

心脏电生理：数字孪生与反演折返灶



心肌中的螺旋波 —— 心律失常的标志性时空斑图

- 控制方程:反应-扩散型 PDE(单域 / 双域模型),描述电信号在心肌中的传播
- 与第二章呼应: 这正是相场 / Allen-Cahn 一类方程在心脏中的体现, 行波、螺旋、斑图皆源于此

正问题:心脏数字孪生


- 给定个体心脏几何 + 电导参数,正向模拟电激动传播
- 用于术前规划、药物 / 消融方案的虚拟测试
- 代理模型将单次数小时的模拟转变为快速反复评估

反问题:EP-PINN 反演组织参数

- 输入:导管 / 体表测到的稀疏电信号
- EP-PINN 以反应-扩散方程为约束,反推激活时间、传导速度等不可直接测量的组织参数
- 目标:定位折返灶 / 异常传导区,指导射频消融

同一套反应-扩散方程,正向用于孪生预测、反向用于参数反演, 再次体现正 / 反问题的对照。

医学成像：波动方程反问题的又一实例



超声 CT 环形阵列:四周发射 / 接收,反演体内声速(示意)

超声层析(USCT):反演声速分布

环形阵列绕乳腺发射超声、接收散射信号，通过全波形反演重建组织声速图，良 / 恶性组织声速不同，故可成像。无电离辐射。

地震 FWI 为「地表声波 → 地下速度」，USCT 为「体表声波 → 体内声速」：
控制方程均为波动方程，数学形式 $\min \|F(c) - d\|^2$ 完全一致，同一方法可同时应用于地球与人体

AI 的三种切入

1 学习正则项

用网络学习组织结构的先验,替代手工正则,稳定病态反演

2 端到端重建

直接学「测量信号 $\leftrightarrow$ 声速图」,推理即输出图像,适合实时成像

3 代理加速

神经算子替代波动方程正演，大幅缩短每次迭代时间


相关方法: 光声成像、电阻抗成像(EIT)、扩散光学,均为「外部测量反演内部物理场」的 PDE 反问题,AI 的切入逻辑一致。

高维方程：网格方法彻底失效的领域

前述领域多为二 / 三维空间;但有一类 PDE 维数高达几十、上百,无法采用网格离散。

高维的来源

- 金融:篮子期权 / 风险定价 → 维数 = 资产个数(几十 ~ 上百)
- 随机控制:Hamilton–Jacobi–Bellman 方程,维数 = 状态空间维度
- 量子多体:N 电子 Schrödinger 方程,波函数定义在 $3N$ 维空间
- 统计物理:Fokker–Planck 方程,维数 = 粒子自由度



网格点数随维数指数增长

维数灾难

每维放 m 个点, d 维就需要 m^d 个网格点。取 $m=10$ 、 $d=100$,需要 10^{100} 个点, 远超可观测宇宙的原子数($\sim 10^{80}$)。任何基于网格的方法(FDM / FEM / 谱方法)在此完全失效。


出路:以采样替代网格

蒙特卡洛积分误差按 $n^{(-1/2)}$ 收敛, 而该速率与维数 d 无关; 这是高维空间中关键的可依赖手段。

因此, 高维 PDE 的神经网络解法几乎都建立在将 PDE 改写为可采样的随机表示之上

Deep BSDE: 用倒向随机微分方程解百维 PDE

- 理论桥梁: 非线性 Feynman–Kac 公式表明, 一大类抛物型 PDE 等价于一个倒向随机微分方程(BSDE)
- Han, Jentzen & E(PNAS 2018): 将 BSDE 的求解转化为一个深度学习问题
- 未知的解 $u(0, \cdot)$ 设为待优化参数; 每个时间步的梯度 $\nabla u(t_n, \cdot)$ 用一个神经网络表示
- 沿大量随机样本轨迹前向模拟, 以终端条件匹配为损失训练, 全程只需采样, 无需网格



蒙特卡洛随机路径:沿轨迹采样替代网格铺点


三个步骤

- PDE $\rightarrow$ (Feynman–Kac) $\rightarrow$ 等价 BSDE
- 用神经网络参数化每步的梯度, 沿路径前向推进
- 最小化终端误差 $\rightarrow$ 同时得到 u 与 ∇u

- 100 维带违约风险的非线性定价方程, 误差到千分量级
- 高维 HJB、Allen–Cahn 等同框架求解
- 从根本上消除 PDE 求解中的维数灾难

核心结论: 将确定性 PDE 改写为可采样的随机过程, 神经网络仅负责拟合其中的梯度场

量子多体：用神经网络表示波函数



电子密度 / 轨道结构(示意)

- 目标方程: 定态 Schrödinger 方程 $\hat{H}\psi = E\psi$
- 维数 = $3N$ (N 个电子), 且波函数须满足反对称(交换两电子变号), 经典网格方法无法处理

FermiNet / PauliNet: 将反对称嵌入网络结构


- 用神经网络表示高维波函数 $\psi(r_1, \dots, r_N)$
- 通过行列式(Slater)结构强制反对称, 将物理约束直接编码进网络, 而非通过损失函数学习
- 天然处理电子间的多体关联, 表达力远超传统拟设

变分蒙特卡洛(VMC)训练

- 变分原理: 能量泛函的最小值就是基态能量
- 用蒙特卡洛在 $3N$ 维位形空间采样估计能量与梯度
- 无需标签: 物理(能量最低)本身即为训练目标
- 精度可达甚至超越 CCSD(T) 等高阶量子化学方法

与 PINN 理念一致: 将物理(反对称 + 变分原理)嵌入网络结构与损失, 而非依赖海量数据拟合。

方法选型决策树



本章总结：六个领域，一套方法论

领域	代表系统 / 方法	核心招式	成效
气象预报	Pangu · GraphCast · GenCast · AIFS	算子学习 + 集合	$\sim 10^4\times$ 加速,已业务化、超越物理模式
碳封存	Nested FNO	多级嵌套算子	$\sim 7\times 10^5\times$, 概率评估从年→秒
工程仿真	Geo-FNO · SimAI · DrivAerNet++	几何自适应代理	气动评估 小时 → 毫秒, 进设计闭环
流场 / 生医	HFM · EP-PINN · 无创 FFR	PINN 反问题	稀疏观测 + 物理 → 重建不可测量
高维方程	Deep BSDE · FermiNet	随机表示 + 采样	破百维诅咒; 波函数达化学精度
材料设计	FNO 代理 + 生成模型	正快评 + 反生成	逆向设计 周 → 小时

1 数据的上游仍是 PDE

AI 建立在高保真求解器 / 再分析数据之上, 物理并未退出, 而是转入幕后

2 AI 压缩的是反复求解环节

瓶颈从不在单次求解, 而在反复求解、高维与实时; 代理压缩中间环节, 两端交由数值方法

3 物理进结构与损失

PINN / PINO / 神经波函数的共性: 将守恒、对称、方程嵌入模型,而非仅依赖数据